

1.项目结构

```
pythonProject1/
├── data/
│   ├── nyt.csv           # NYT 新闻数据集 (text, label)
│   ├── ag.csv           # AG News 数据集 (text)
│   └── glove.6B.100d.txt # 预训练 GloVe 100 维词向量
├── split_data.py        # 数据划分脚本 (运行一次即可)
├── split.pkl            # 划分结果, 供后续任务复用
├── task1_bow.py         # Task 1: Bag of Words
├── task1_results.csv    # Task 1 结果
├── task2_word2vec.py    # Task 2: Word2Vec / GloVe
├── task2_results.csv    # Task 2 结果
├── task3_bert.py        # Task 3: BERT 微调
├── task3_results.csv    # Task 3 结果
└── bert_nyt/           # BERT 训练输出目录 (自动生成)
```

2. 环境及依赖

Python 3.12

主要依赖:

Numpy

Pandas

scikit-learn

Gensim

Torch

Transformers

accelerate

3. 数据集

data/目录下为本次实验用到的数据集:

nyt.csv	NYT 数据集，包含 text 和 label 两列
ag.csv	AG News 数据集，包含 text 列
	GloVe 100 维词向量，从
glove.6B.100d.txt	http://nlp.stanford.edu/data/glove.6B.zip 解压获得

4. 代码文件对应任务

`split_data.py`: 数据划分。按 8 : 1 : 1 划分为 Training / Validation / Test，生成 `split.pk1`，以便后续使用。

`task1_bow.py`: Task 1。使用 Binary Bag of Words 和 Word Frequency 两种词袋表示，分类器统一使用 Logistic Regression，在 NYT Test Set 上评价，生成 `task1_results.csv`。

`task2_word2vec.py`: Task 2。使用 100 维词向量，文档向量取文档内所有有效词向量的平均，分类器统一使用 Logistic Regression。完成三组实验：Pre-trained GloVe、Word2Vec trained on AG News、Word2Vec trained on NYT，在 NYT Test Set 上评价，生成 `task2_results.csv`。

`task3_bert.py`: Task 3。微调 bert-base-uncased，最大序列长度为 64，训练 3 个 epoch，在 NYT Test Set 上评价，生成 `task3_results.csv`。